

18. Kompilátor

- kompilátor slouží pro překlad algoritmů zapsaných ve vyšším programovacím jazyce do jazyka nižšího, nejčastěji strojového (assembly)
- převádí jeden jazyk na jiný
- z matematického hlediska se jedná o mapovací funkci
- typickým příkladem kompilovaného jazyka je C

1. Stavba

- Fáze překladu programu:
 - nejčastěji je zkompileovaný program rozprostřen do několika menších programů, *fragmentace zdrojového kódu*, lepší údržba zdrojového kódu a navíc nižší nároky na kompilátor
 - z tohoto důvodu kompilátor překládá jednotky zdrojového kódu do tzv. *objektového kódu*
 - objektový kód už je v podstatě strojovým kódem dané architektury, obsahuje dodatečné informace, vazby na externí proměnné či kód
 - z jednotlivě přeložených objektových kódů sestaví linker spustitelný program
 - příklad z jazyka C: `program.c` → `program.asm` (kompilátor jazyka C), `program.asm` → `program.obj` (assembler, vytvoření objektového kódu), `program.obj` + `knihovna.lib` → output (linker; spojení objektů a knihoven do spustitelného kódu)
- často bývají kompilátory rozdělené na dvě části, první je závislá na vstupním jazyce a druhá je závislá na cílové architektuře
- překlad nemusí probíhat přímo, často se generuje tzv. mezikód, kód mezi přechodem z front-endu na back-end
 - dělení kompilátoru na dva menší jednoduché
 - a zároveň jeden mezikód je univerzální mezi architekturami
 - konkrétně v C se mezikód nazývá *přenositelný assembler*
- JIT, just-in-time kompilace, kompiluje se pouze mezikód, tudíž všechny chyby už jsou vyloučeny, byly nalezeny v první části kompilace, přitom mezikód může být interpretován například virtuálním strojem
- překladač může kromě zdrojového kódu dostat i *options*, požadovaná míra optimalizace, povolená syntaxe atd.

2. Fungování a význam

- Části překladače:
 - **Lexikální analyzátor**: má za úkol získat ze vstupního kódu tzv. *lexémy* (něco jako klíčová slova - if), všechny lexémy jsou popsány pomocí regulárního jazyka, k jejich rozpokznání se používá konečný automat, do další fáze se kromě lexému posílá identifikátor, u nich se odkazujeme na tabulku identifikátorů, takže se v dalších fázích nemusí pracovat s textem, urychlení překladu
 - **Syntaktický analyzátor**: analyzuje, zda-li je program zapsán správně kontextově, například po *begin* musí v programu následovat *end*, určuje jak se jednotlivé příkazy budou zpracovávat dále, vyhodnocuje pořadí, využívá se bezkontextové gramatiky, výsledkem je *syntaktický strom*, popisuje strukturu programu

- **Sémantický analyzátor:** zpracovává syntaktický strom a provádí význam jednotlivých operací, takže syntaktický analyzátor studuje strukturu programu, zatímco sémantický studuje správnost jednotlivých operací, provádí se typová analýza (správné datové typy), dále kontrola pravé a levé strany přiřazovacího příkazu, výstupem je obohacený syntaktický strom
- **Překladač do mezikódu:** ze syntaktického stromu se stává lineární kód, tzv. *mezikód*
- **Optimalizátor:** úprava mezikódu, odstranění cyklického přiřazení či mrtvých větví kódu, kombinace, nahrazení volané funkce jejím obsahem, ...
- **Generátor kódu:** poslední fáze, kdy se z mezikódu generuje finální spustitelný kód pro danou architekturu, nejčastěji je výstup ve strojovém jazyce

3. Porovnání s ostatními přístupy

- vedle kompilačního přístupu ještě rozlišujeme přístup interpretační a hybridní
- podle toho se dají rozdělit jazyky na interpretované (Python, Perl), kompilované (C, Go, Rust) a hybridní (Java)
- výhody interpretovaných jazyků:
 - zejména rychlost vývoje, není třeba kompilace
 - laditelnost, není tu optimalizátor, takže není struktura kódu upravována a umožňuje lepší kontrolu nad výsledkem
 - kompatibilita, stejný program bude spustitelný na různých architekturách a operačních systémech
 - správa paměti, při interpretaci nemusejí být proměnné vázány na fyzickou adresu v paměti, proto je možné aktivní přemapování, zabránění fragmentace paměti
 - obecně je snazší vytvořit interpreter, než kompilátor, lépe se modifikují pro experimentálnější jazyky
- mezi hlavní nevýhody interpretovaných jazyků je výsledná pomalost oproti jazykům zkompilovaným
- interpreter spouští kód přímo, zatímco kompilátor nikoliv, ten pouze konvertuje
- příklady kompilátorů: Javac (jazyk Java, kód je kompilován do bytekódu - to je v podstatě komprimovaný mezikód, ten je posléze interpretován, takže je hybridní), GNU Compiler Collection (open-source kompilátor, C - gcc, zavolá se kompilátor pro daný jazyk, poté se spustí assembler, linker a vygeneruje se binární spustitelný soubor)

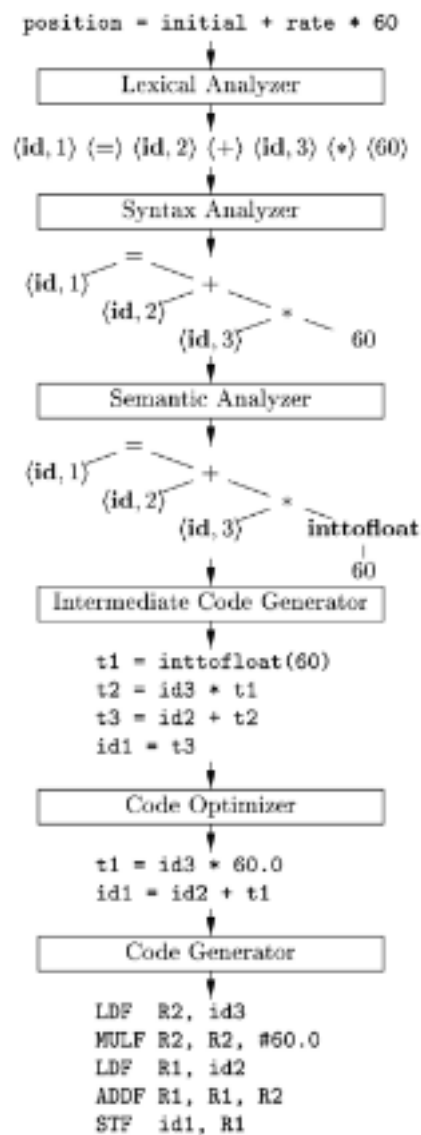


Figure 1: Příklad přechodového grafu KA